

# Лекция 11. Продвинутое управление потоками

ИУ8

November 17, 2016

## План лекции:

- пул потоков
- прерывание работы потоков

## Объект потока

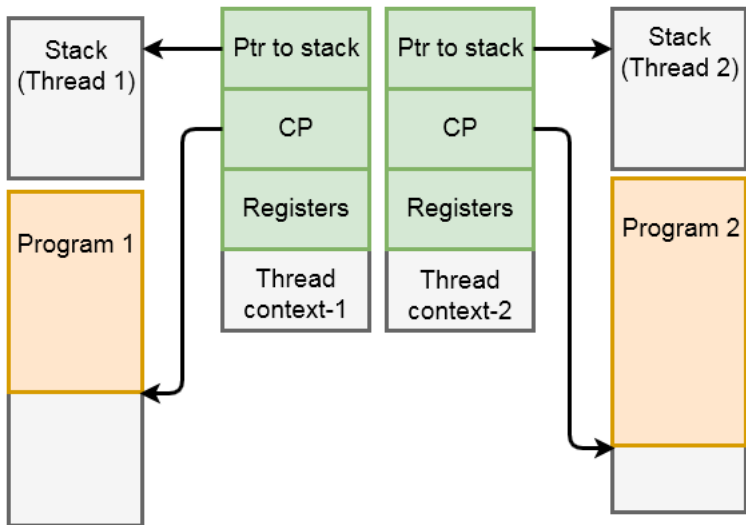
Чтобы ОС поддерживала многозадачность, каждый выполняемый поток должен обладать своим контекстом исполнения.

Этот контекст используется для хранения данных о текущем состоянии потока

Таким образом контекст состоит как минимум из

- значения регистров процессора
- указатель на стек потока
- счетчик команд

# Memory



Таким образом, каждый новый поток занимает некоторый объем оперативной памяти.

Идем дальше.

## Переключение контекста

В системе количество потоков может превышать число ядер, тогда будет применяться механизм переключения задач.

В произвольный момент времени ОС передает поток на исполнение процессору. Этот поток исполняется в течение некоторого временного интервала. После завершения этого интервала контекст ОС переключается на другой поток. При этом происходит следующее:

- 1 обновляется контекст потока;
- 2 из набора имеющихся потоков выбирается один, который будет исполняться на процессоре;
- 3 значения из выбранного контекста потока загружаются во внешнее окружение.

## Context Switching

Total cost of  
context switching

Multitasking



vs. Multitasking with context switching



Получаем, что новые потоки не только занимают объем оперативной памяти, но и создают дополнительные временные издержки, так как операционной системе приходится планировать исполнение потоков и выполнять переключения контекста.

## Пул потоков

Во многих системах бессмысленно заводить отдельный поток для каждой задачи, которая потенциально может выполняться одновременно с другими, но тем не менее хотелось бы пользоваться благами параллелизма там, где это возможно.

Именно это позволяет сделать пул потоков: задачи, которые могут выполняться параллельно, отправляются в пул, а тот ставит их в очередь ожидающих работ. Затем один из рабочих потоков забирает задачу из очереди, исполняет ее и принимается за следующую задачу.



## Простейший пул потоков

```
1 class thread_pool {
2     std::atomic_bool done = false;
3     thread_safe_queue<std::function<void()>> work_queue;
4     std::vector<std::thread> threads;
5
6     void worker_thread(){
7         while(!done.load()) {
8             std::function<void()> task;
9             if(work_queue.try_pop(task)) {
10                 task();
11             } else {
12                 std::this_thread::yield();
13             }
14         }
15     }
16 public :
17     ~thread_pool() {
18         done.store(true);
19     }
```

## Простейший пул потоков: продолжение

```
1  thread_pool(){
2      int const thread_count = std::thread::hardware_concurrency();
3      try {
4          for(auto i = 0; i < thread_count; ++i) {
5              threads.push_back(std::thread(
6                  &thread_pool::worker_thread,
7                  thit));
8          }
9      } catch(...) {
10         done.store(true);
11     }
12 }

13
14 template<typename Func>
15 void submit(Func f) {
16     work_queue.push(std::function<void()>(f));
17 }
18 }; // end of thread_pool
```

Пул потоков с возможностью получения результата задачи

см `thread_pool.h`

## Как модифицировать пул

- динамически изменять количество рабочих потоков
- для каждого потока создать свою очередь задач
- предоставить доступ к списку задач
- добавить в пул потоков дополнительных рабочих

## Динамическое число рабочих

Суть: в зависимости от количества задач изменять количество рабочих потоков

- + не занимаем ОП под потоки, которые ожидают задач
- + снижаем конкуренцию при доступе к очереди задач
- + уменьшаем количество потоков в ОС
  - усложняется логика работы пула
  - тратим дополнительное время на создание потока

## Отдельные очереди задач

Суть: чтобы общая очередь задач не стала узким местом, создаем по очереди задач для каждого потока

- + сводим конкуренцию за доступом к очереди задач к минимуму
  - усложняется логика работы пула
  - возможна ситуация обработки наиболее «длительных» задач только одним потоком, тогда как остальные потоки простаивают

## Доступ к ресурсам пула

Суть: если мы имеет дополнительный вычислительный ресурс, то можем выполнять задачи из очереди задач пула потоков

- + динамически увеличиваем вычислительные способности пула
- + уменьшаем вероятность блокировки задач
- усложнение логики работы пула

## Прерывание потоков

Бывают ситуации, когда требуется сообщить работающему потоку о необходимости остановки.

Например, программа в отдельном потоке скачивает файл, но пользователь решил отметить это действие.

Важно понимать, что выполняемая задача должна сама по себе поддерживать прерывания

Для приостановки/продолжения работы потока в ОС, которые поддерживают такой функционал, используйте функции ОС и `native_handle()`. Например, в ОС Windows используйте `SuspendThread` и `ResumeThread`.



```

1 struct interrupt_flag {
2     void set();
3     bool is_set() const;
4 };
5 thread_local interrupt_flag this_thread_interrupt_flag;
6 class interruptible_thread {
7     std::thread internal_thread;
8     interrupt_flag* flag;
9 public: template<typename FunctionType>
10    interruptible_thread(FunctionType f) {
11        std::promise<interrupt_flag*> p;
12        internal_thread=std::thread([f,&p] {
13            p.set_value(&this_thread_interrupt_flag);
14            try {
15                f();
16            } catch(interruption_exception const &) {}
17        });
18        flag=p.get_future().get();
19    }
20    void interrupt() {
21        if(flag) {
22            flag->set();
23        }
24    }
25 };

```

## Обнаружение прерывания

Реализуем функцию, проверяющую необходимость остановки потока

```
1 void interruption_point() {  
2     if(this_thread_interrupt_flag.is_set())  
3         throw interruption_exception;  
4 }
```

```
1 int main() {  
2     interruptible_thread th([]){  
3         byte data[2048];  
4         int received = receive_data(data);  
5         while(received) {  
6             interruption_point();  
7             received = receive_data(data);  
8         }  
9     });  
10    //...  
11    th.interrupt();  
12 }
```

Отлично, прерывать активные потоки мы умеем.

Но хотелось бы еще и прерывать потоки, которые находятся в режиме ожидания

Рассмотрим, как обрабатывать прерывания потоков, ожидающих сигнала условной переменной

```

1 template<typename Lockable>
2 struct custom_lock {
3     interrupt_flag* self;
4     Lockable& lk;
5
6     custom_lock(interrupt_flag* self_,
7                 std::condition_variable_any& cond,
8                 Lockable& lk_):
9         self(self_),lk(lk_)
10    {
11        self->set_clear_mutex.lock();
12        self->thread_cond_any=&cond;
13    }
14    void unlock() {
15        lk.unlock();
16        self->set_clear_mutex.unlock();
17    }
18    void lock() {
19        std::lock(self->set_clear_mutex,lk);
20    }
21    ~custom_lock() {
22        self->thread_cond_any = nullptr;
23        self->set_clear_mutex.unlock();
24    }
25 };

```

```

1 class interrupt_flag {
2     std::atomic<bool> flag;
3     std::condition_variable_any* thread_cond_any = nullptr;
4     std::mutex set_clear_mutex;
5
6 public:
7     void set() {
8         flag.store(true);
9         std::lock_guard<std::mutex> lk(set_clear_mutex);
10        if(thread_cond_any) {
11            thread_cond_any->notify_all();
12        }
13    }
14
15    template<typename Lockable>
16    void wait(std::condition_variable_any& cv, Lockable& lk) {
17        custom_lock cl(this, cv, lk);
18        interruption_point();
19        cv.wait(cl);
20        interruption_point();
21    }
22 };

```

Осталось реализовать функцию, которая позволяет потоку ожидать условную переменную с возможностью прерывания

```
1 template<typename Lockable>
2 void interruptible_wait(
3     std::condition_variable_any& cv,
4     Lockable& lk)
5 {
6     this_thread_interrupt_flag.wait(cv, lk);
7 }
```

Для реализации прерывания потоков, которые ожидают другие блокирующие сущности, будет полезно использовать методы `wait_for`

```
1 template<typename T>
2 void interruptible_wait(std::future<T>& fut)
3 {
4     while(!this_thread_interrupt_flag.is_set()) {
5         if(fut.wait_for(std::chrono::milliseconds(1)
6             == std::future_status::ready)
7             break;
8         }
9         interruption_point();
10 }
```

## Обработка прерываний

Реализованное прерывание - это не что иное как исключение. Это исключение следует обрабатывать.

Можно перехватить и продолжить работу дальше. Можно перехватить и завершить работу функции, а следовательно, и потока.

Если же исключение выйдет за пределы функции потока, переданной в конструктор потока, то будет вызвана функция `std::terminate`, что, в свою очередь, приведет к завершению программы.



## На следующих лекциях:

- Структуры данных, свободные от блокировок
- Сетевое взаимодействие
- ???
- ???
- Зачет

## Самостоятельное изучение

- Реализуйте модификации пулов потоков, описанные **в лекции (жми здесь)**
- <https://habrahabr.ru/post/306332/>

## Список литературы

- Уильямс - Параллельное программирование на C++ в действии
- <http://www.jlc.tcu.edu.tw/OS/932/threadmanager.pdf>
- [https://www.cs.uic.edu/~jbell/CourseNotes/OperatingSystems/4\\_Threads.html](https://www.cs.uic.edu/~jbell/CourseNotes/OperatingSystems/4_Threads.html)
- <https://habrahabr.ru/post/306332/>